

Propuesta técnica: videos de lengua de señas a avatar web

Para la plataforma de enseñanza de lengua de señas, el objetivo sería convertir videos originales de personas realizando cada seña en animaciones que un avatar 3D pueda reproducir dentro de la web. No se genera un avatar por video: se usa un único avatar humanoide estándar y reutilizable, al que se le transfieren los movimientos de brazos, manos, dedos, cabeza y, posteriormente, expresiones faciales.

Enfoque recomendado

Usaría un avatar en formato VRM 1.0, basado en glTF 2.0. VRM estandariza huesos humanoides y expresiones, lo que simplifica asignar los movimientos extraídos de un video al esqueleto 3D. Para producir el primer personaje, VRoid Studio permite crear y exportar un archivo .vrn. Ready Player Me puede servir para una demo visual rápida, pero no lo tomaría como base definitiva: el control del rig de dedos y de expresiones es especialmente importante para lengua de señas.

La web puede desarrollarse con Next.js + TypeScript; React Three Fiber/Three.js para el render 3D; y @pixiv/three-vrm para cargar el avatar VRM.

Proceso propuesto

- Video de la persona haciendo una seña
 - ↓ Extracción de pose, manos y rostro por frame
 - ↓ Limpieza, normalización y corrección de movimiento
 - ↓ Conversión de landmarks a rotaciones de huesos
 - ↓ Generación de animación reutilizable por seña
 - ↓ Reproducción del avatar 3D en la plataforma

1. Preparar videos. Grabar con cámara frontal fija, buena luz, fondo simple, manos visibles y postura neutra al inicio/final. Evitar modo espejo, pues puede intercambiar izquierda y derecha.
2. Detectar movimiento. Procesar los videos con MediaPipe Holistic Landmarker en modo video. Para el MVP se priorizan hombros, codos, muñecas y articulaciones de los dedos; las expresiones faciales se agregan después.
3. Normalizar y limpiar. Centrar los puntos usando el torso y escalar con la distancia entre hombros. Aplicar smoothing para reducir jitter, interpolar pérdidas breves de tracking y eliminar silencios al inicio/final.
4. Retargeting. Convertir cadenas de landmarks a rotaciones de hueso: hombro-codo para brazo superior, codo-muñeca para antebrazo y cadenas de nudillos/falanges para cada dedo. Guardar keyframes como cuaterniones y suavizarlos.
5. Guardar animación. Producir un JSON por seña —fuente de verdad editable y regenerable— y, si hace falta optimizar distribución, exportar después una animación GLB/VRM embebida.
6. Reproducir en la lección. Mostrar video humano como referencia y avatar como vista controlable: repetir, 0.25x, 0.5x o 1x, y en una siguiente versión cambiar ángulo de cámara para observar orientación de manos.

MVP sugerido

Empezaría con 5–10 señas. La meta inicial es lograr fidelidad en brazos, muñecas, palmas y dedos; no traducir automáticamente lengua de señas. Tras validarlo con personas usuarias de la lengua objetivo o intérpretes, se pueden sumar expresiones faciales, más vocabulario, ejercicios y reconocimiento de señas hechas por los estudiantes.

La decisión clave es mantener un avatar VRM reutilizable y transferir el movimiento de cada video a ese avatar. Esto reduce costos, mantiene una identidad visual consistente, mejora la reproducibilidad y deja los videos originales como referencia pedagógica.

Referencias técnicas

- MediaPipe Holistic Landmarker — developers.google.com/edge/mediapipe/solutions/vision/holistic_landmarker
- MediaPipe Pose Landmarker Web — developers.google.com/edge/mediapipe/solutions/vision/pose_landmarker/web_js
- VRM Specification — github.com/vrm-c/vrm-specification
- VRoid Studio: exportación VRM — vroid.pixiv.help/hc/en-us/articles/38726063278233-How-do-I-export-a-model-as-VRM
- Khronos glTF — khronos.org/glTF/